

Углубленное машинное обучение и искусственный интеллект в Python

Патласов Дмитрий Александрович, ПГНИУ
dmitriypatlasov@gmail.com

ПРОБЛЕМА "ЧЕРНОГО ЯЩИКА"

Сложность современных архитектур

Парадигма глубокого обучения строится на представлении признаков во множестве скрытых слоев. Миллионы нелинейных взаимодействий делают прямое отслеживание логики вывода невозможным для человека. В критических доменах (медицина, финансы, судебная система) отсутствие прозрачности ведет к существенным рискам.



| ЧТО ТАКОЕ EXPLAINABLE AI (XAI)?



Прозрачность

Возможность понять внутреннее устройство алгоритма обучения, структуру графа вычислений и распределение весов.



Интерпретируемость

Способность предоставить понятное человеку обоснование принятого решения на качественном или количественном уровне.



Доверие (Trust)

Основано на верификации того, что модель принимает решения по причинно-следственным связям, а не случайным шумам.

КОМПРОМИСС: ТОЧНОСТЬ VS ИНТЕРПРЕТИРУЕМОСТЬ



Цель XAI — расширить возможности сложных архитектур до уровня прозрачности линейных моделей без потери точности.

| ЗАКОНОДАТЕЛЬНЫЕ ТРЕБОВАНИЯ К AI

-  **GDPR (Статья 22):** Фиксирует право гражданина Европейского Союза на получение разъяснений по поводу решений, принятых автоматизированными системами.
-  **EU AI Act:** Классифицирует системы искусственного интеллекта по уровням риска. Модели высокого риска обязаны обеспечивать трассируемость и прозрачность.
-  **Регулирование финансового сектора:** Запрещает дискриминацию (биас) в скоринге заемщиков на основе скрытых корреляций.

| ЭТИЧЕСКИЕ АСПЕКТЫ ПРОЗРАЧНОСТИ

Минимизация предвзятости

Нейронные сети склонны запоминать и масштабировать скрытые предрассудки, содержащиеся в исторических обучающих выборках.

Инструменты ХАИ позволяют локализовать проявления дискриминации на этапе валидации модели.

Справедливость

Исключение защищенных признаков (раса, пол) из факторов прямого и косвенного влияния.

Подотчетность

Возможность внешнего аудита решений нейросети независимыми экспертами.

| РИСКИ ЛОЖНЫХ ЗАВИСИМОСТЕЙ

//

"Если модель делает идеальные предсказания на основе ложного сигнала (например, классифицирует пневмонию по маркеру рентген-аппарата), она рухнет при первом столкновении с реальным клиническим потоком."

— Риск ложной корреляции (Spurious Correlation)

КЛАССИФИКАЦИЯ МЕТОДОВ ХАІ

Критерий	Model-Agnostic (Универсальные)	Model-Specific (Специализированные)
Локальные (Local)	LIME, SHAP (Kernel), Counterfactuals	Integrated Gradients, Grad-CAM, Attention Maps
Глобальные (Global)	PDP, ALE, Global Surrogates, PFI	Tree SHAP, Визуализация фильтров сверточных слоев
Внутренние (Intrinsic)	Линейные модели, Деревья решений, GAM	

ЛИНЕЙНЫЕ И ЛОГИСТИЧЕСКИЕ МОДЕЛИ

Количественная мера вклада

В линейных моделях весовые коэффициенты напрямую отражают силу влияния признака на целевую переменную при прочих равных условиях.

$$y = \beta_0 + \sum_{i=1}^p \beta_i x_i + \epsilon$$

Ограничение: Линейность и отсутствие учета сложных нелинейных взаимодействий.

| ДЕРЕВЬЯ РЕШЕНИЙ (DECISION TREES)

Иерархические структуры правил

Принятие решений осуществляется путем последовательного разбиения признакового пространства на основе пороговых значений.

Преимущества: Полная трассируемость пути вывода от корня к листу.
Легко визуализировать в виде графа.

Проблема: Деревья большой глубины теряют интерпретируемость из-за чрезмерной ветвистости.

ОБОБЩЕННЫЕ АДДИТИВНЫЕ МОДЕЛИ (GAM)

GAM

ЛОКАЛЬНЫЕ ГЛАДКИЕ ФУНКЦИИ

Учет нелинейности без усложнения

GAM заменяют линейные коэффициенты на нелинейные функции гладкости (сплайны) для каждого признака независимо.

$$g(E(Y)) = \beta_0 + f_1(x_1) + \dots + f_p(x_p)$$

Каждую функцию $f(x)$ можно легко построить на двумерном графике для интерпретации.

| АЛГОРИТМ RULEFIT

-  **Синтез правил и линейных моделей:** Генерация набора правил на основе неглубоких деревьев решений.
-  **Lasso-регуляризация:** Автоматический отбор наиболее значимых правил из тысяч сгенерированных.
-  **Итоговая интерпретация:** Модель представляет собой взвешенную сумму исходных признаков и бинарных правил.

БАЙЕСОВСКИЕ СПИСКИ ПРАВИЛ (BRL)



Структура IF-THEN

Модель формирует последовательность вероятностных правил, легких для восприятия экспертами.



Априорное распределение

Задаёт предпочтение более коротким и простым спискам правил для предотвращения переобучения.



Вероятностный вывод

Выдает не просто класс, а апостериорную вероятность принадлежности к классу.

Локальные методы пост-хок объяснения

Анализ индивидуальных предсказаний сложных моделей общего вида

ЛОКАЛЬНОЕ ОБЪЯСНЕНИЕ: ОСНОВНАЯ ИДЕЯ

Почему локальность проще?

Граница принятия решений сложной модели (например, глубокой нейросети) в глобальном масштабе крайне извилиста и нелинейна.

Однако, если мы сфокусируемся на конкретной точке данных и ее ближайших соседях, граница становится локально линейной.



АЛГОРИТМ LIME: ТЕОРИЯ

Local Interpretable Model-agnostic Explanations находит локально аппроксимирующую простую модель g , минимизируя следующую функцию потерь:

$$\xi(x) = \arg \min_{g \in G} L(f, g, \pi_x) + \Omega(g)$$

Где L — мера расхождения прогнозов исходной модели f и суррогата g ; π_x — ядро близости, определяющее вес окрестности; $\Omega(g)$ — мера сложности модели-интерпретатора.

| LIME ДЛЯ ТАБЛИЧНЫХ ДАННЫХ

Шаг 1: Пертурбация

Генерация новых синтетических точек путем случайного изменения значений признаков вокруг исходного наблюдения.

Шаг 2: Взвешивание

Назначение веса каждому объекту в зависимости от его расстояния до исходного (с использованием экспоненциального ядра).

| LIME ДЛЯ ТЕКСТОВ (NLP)



Маскирование

Создание вариаций текста путем случайного удаления отдельных слов или токенов из исходного предложения.



Оценка весов

Обучение локальной линейной регрессии, где коэффициенты отражают влияние присутствия слова на итоговый класс.



Результат

Маркировка слов цветом в зависимости от их роли (позитивное/негативное влияние на классификацию).


LIME ИЗОБРАЖЕНИЯ

LIME: Сегментация суперпикселей

Изображение разбивается на однородные сегменты (суперпиксели).

Вариации создаются путем случайной заливки серым цветом подмножеств суперпикселей.

Итоговое объяснение подсвечивает суперпиксели, которые вносят наибольший вклад в итоговую вероятность класса.



| АЛГОРИТМ ANCHORS

-  **Понятие Якоря (Anchor):** Нахождение минимального подмножества условий (например, "Возраст > 45 и Доход < 30k"), при которых модель всегда дает одинаковый прогноз независимо от остальных признаков.
-  **Высокая точность (Precision):** Гарантия того, что в рамках найденного якоря вероятность изменения прогноза стремится к нулю.
-  **Покрытие (Coverage):** Оценка того, для какой доли датасета данное правило остается справедливым.

Глобальные методы пост-хок объяснения

Понимание агрегированного поведения модели на всей выборке

ГРАФИК ЧАСТИЧНОЙ ЗАВИСИМОСТИ (PDP)

Предельное влияние признака

PDP показывает маргинальный эффект одного или двух признаков на прогнозируемый результат машинного обучения.

$$\hat{f}_{x_S} (x_S) = \frac{1}{n} \sum_{i=1}^n \hat{f} (x_S, x_C^{(i)})$$

Ограничение: Предполагается независимость исследуемого признака от остальных.




КРИВЫЕ ИНДИВИДУАЛЬНОГО ОЖИДАНИЯ (ICE)

Детализация PDP

В отличие от PDP, усредняющего зависимости, ICE строит отдельную линию прогноза для каждого индивидуального наблюдения в выборке.

Польза: Позволяет обнаружить скрытые гетерогенные эффекты и взаимодействия признаков, которые нивелируются при усреднении на PDP.



| ACCUMULATED LOCAL EFFECTS (ALE)

ALE

РЕШЕНИЕ ПРОБЛЕМЫ КОРРЕЛЯЦИИ

Преимущество над PDP

Если признаки сильно скоррелированы, PDP вычисляет нереалистичные сценарии (например, площадь дома 500 кв.м при 1 комнате).


ALE решает эту проблему, вычисляя разности предсказаний исключительно в узких локальных интервалах значений признака.

ГЛОБАЛЬНЫЕ СУРРОГАТНЫЕ МОДЕЛИ


Аппроксимация Черного Ящика

Мы берем сложную модель f и обучаем простую интерпретируемую модель g (например, дерево решений) на прогнозах модели f , а не на исходных метках.

Метрика верности (R^2): Показывает, насколько точно суррогат воспроизводит логику сложной системы.



ВАЖНОСТЬ ПРИЗНАКОВ НА ОСНОВЕ ПЕРЕСТАНОВОК



Принцип: Случайное перемешивание значений одного признака разрушает его связь с таргетом. Падение метрики качества (например, ROC-AUC) определяет его важность.

Теория игр и метод

Справедливое распределение вклада признаков на базе концепции Ллойда
Шепли

SHAP

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ: ЗНАЧЕНИЯ ШЕПЛИ

Значение Шепли определяет вклад игрока в кооперативной игре. В машинном обучении игроки — признаки, игра — предсказание.

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)]$$

Алгоритм перебирает все возможные коалиции признаков, чтобы рассчитать средний маргинальный вклад признака i .

ЧЕТЫРЕ АКСИОМЫ ЗНАЧЕНИЙ ШЕПЛИ

Аксиома	Описание	Суть для машинного обучения
Эффективность	Сумма вкладов признаков равна разнице между прогнозом и базовым мат. ожиданием.	Полное объяснение отклонения без остатка.
Симметричность	Если два признака вносят равный вклад в любые коалиции, их значения Шепли равны.	Равное влияние получает равную оценку.
Болван (Dummy)	Признак, не меняющий прогноз, получает нулевое значение Шепли.	Бесполезные признаки получают нулевой вес.
Аддитивность	Вклады признаков в ансамбле моделей можно линейно суммировать.	Легко агрегировать объяснения моделей.

АДДИТИВНЫЕ ОБЪЯСНЕНИЯ (SHAP)

SHAP объединяет локальные суррогаты и теорию игр, строя аддитивное объяснение в виде линейного уравнения:

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i$$

Где g — модель-объяснение, $z'_i \in \{0,1\}^M$ — вектор присутствия/отсутствия признака в коалиции, ϕ_i — значение SHAP признака.

| KERNELSHAP VS TREESHAP

KernelSHAP (Agnostic)

Использует взвешенную линейную регрессию для аппроксимации значений Шепли. Вычислительно сложен: $O(2^M)$, требует аппроксимаций при большом количестве признаков.

TreeSHAP (Optimized)

Специализированный быстрый алгоритм для древесных ансамблей (XGBoost, CatBoost). Снижает сложность расчета до полиномиальной $O(TLD^2)$.

ВИЗУАЛИЗАЦИЯ SHAP: BEESWARM PLOT

Плотность и распределение влияния

Beeswarm — самый информативный график XAI:

- Каждый признак занимает отдельную строку.
- Каждая точка — объект выборки.
- Смещение по горизонтали — величина значения SHAP.
- Цвет точки обозначает высокое (красный) или низкое (синий) значение признака.



ГРАФИКИ FORCE И DEPENDENCE PLOT



Force Plot

Визуализирует баланс сил: какие признаки отклоняют предсказание от базового значения вверх (красные) или вниз (синие) для конкретного объекта.



Dependence Plot

Двумерная зависимость: значение SHAP как функция истинного значения признака. Позволяет увидеть нелинейные эффекты и взаимодействия.

Объяснение Глубоких Нейронных Сетей


Специфические методы для сверточных архитектур и многослойных перцептронов

ВИЗУАЛИЗАЦИЯ СЛОЕВ CNN

Иерархическая репрезентация

Сверточные нейросети изучают признаки по нарастающей:

- **Начальные слои:** Выделяют простейшие границы, ребра, градиенты цвета.
- **Средние слои:** Формируют шаблоны, текстуры и геометрические фигуры.
- **Глубокие слои:** Объединяют шаблоны в концепты (морды животных, колеса).



АНАЛИЗ ЧУВСТВИТЕЛЬНОСТИ (SENSITIVITY)

Градиент по входу

Показывает, насколько сильно изменится выход нейросети при малом возмущении конкретного пикселя изображения.

Вычисляется через частные производные функции предсказания по вектору входа.

Проблема: Градиентное затухание в глубоких слоях из-за насыщения функций активации (например, Sigmoid или ReLU).



INTEGRATED GRADIENTS (IG)

Integrated Gradients решает проблему затухания градиентов, интегрируя градиент функции вдоль пути от базовой точки x' (черный экран) до целевой x :

$$IG_i^{\text{path}}(x) = (x_i - x'_i) \times \int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

Данный метод полностью удовлетворяет аксиоме полноты (Completeness), распределяя разницу предсказаний без остатка.

МЕТОД SMOOTHGRAD

SmoothGrad убирает шум с карт градиентной чувствительности, усредняя градиенты по зашумленным копиям входа:


$$M_{\text{smooth}}(x) = \frac{1}{N} \sum_{i=1}^N M(x + g)$$

Где $g \sim N(0, \sigma^2)$ — случайный гауссовский шум. Данная операция сглаживает пики на нелинейной поверхности градиента.

СВЕРТОЧНЫЕ СЕТИ

Алгоритм Grad-CAM

Class Activation Mapping использует взвешенные суммы карт активаций последнего сверточного слоя для локализации объектов. Веса определяются глобальным пулингом градиентов по пространственным осям. Функция ReLU отфильтровывает только положительный вклад.




РАЗВИТИЕ GRAD-CAM++

Локализация множественных объектов

Классический Grad-CAM плохо работает, когда на изображении присутствует несколько объектов одного класса.

Grad-CAM++ вводит взвешенные производные второго и третьего порядка, что повышает четкость тепловой карты при выделении множественных и частично перекрытых целей.



АЛЬТЕРНАТИВЫ: SCORE-CAM И ABLATION-CAM



Без градиентов

Устраняют артефакты, связанные с разрывами и затуханием градиентов на сложных ландшафтах оптимизации.



Ablation-CAM

Вычисляет важность канала сверточного слоя путем его обнуления (абляции) и замера падения уверенности классификатора.



Score-CAM

Использует активации в качестве масок пропускной способности, измеряя прямой отклик нейросети на исходном изображении.

Интерпретация Трансформеров и

Современные вызовы прозрачности больших языковых
моделей

LLM

| ЯВЛЯЕТСЯ ЛИ ВНИМАНИЕ ОБЪЯСНЕНИЕМ?

Понятие весов внимания (Attention)

Трансформеры используют механизм Self-Attention для взвешивания связей между токенами в тексте.

Дискуссия: Научные публикации ("Attention is not Explanation" vs. "Attention is not not Explanation") доказывают, что веса внимания не могут быть эквивалентны причинным факторам, так как они трансформируются последующими слоями MLP.



ATTRIBUTION В ЭМБЕДДИНГАХ ТЕКСТОВ

-  **Дискретная природа текста:** К словам нельзя применить стандартный градиент напрямую. Градиент рассчитывается относительно непрерывного векторного пространства эмбеддингов.
-  **Агрегирование векторов:** Градиенты размерности эмбединга (например, 768/1536) проецируются на скалярное значение через скалярное произведение.
-  **Итоговая важность:** Выделение слов в контексте промпта, ответственных за генерацию конкретного ответа LLM.

КОНЦЕПТУАЛЬНЫЕ ВЕКТОРЫ АКТИВАЦИИ (TCAV)

Человеческие понятия в слоях нейросети

TCAV сопоставляет скрытые состояния нейросети с высокоуровневыми человеческими концептами (например, концепт "полосатости" для класса "зебра").

Позволяет определить чувствительность модели к концепту без необходимости явной разметки пикселей.

МЕТРИКИ КАЧЕСТВА ОБЪЯСНЕНИЙ

Метрика	Что измеряет	Метод проверки
Fidelity (Верность)	Насколько точно суррогатное объяснение отражает истинное предсказание модели.	Замер корреляции предсказаний $f(x)$ и $g(x)$.
Robustness (Стабильность)	Чувствительность к микровозмущениям входа, не меняющим прогноз.	Добавление шума ϵ к объекту x ; проверка, не изменились ли веса признаков кардинально.
Flicker (Мерцание)	Наличие скачков важности пикселей на соседних кадрах видеопотока.	Анализ временной когерентности карт активации.

АТАКИ НА МЕТОДЫ ОБЪЯСНЕНИЯ

Состязательные манипуляции (Scaffolding)

Исследования показывают, что методы объяснения уязвимы перед злоумышленниками.

Можно спроектировать адверсариальный фильтр (Scaffolding), который маскирует дискриминационное поведение модели на аудите, но возвращает предвзятые ответы на реальном инференсе.

